

人工智能与机器学习 · 线性模型作业标准解答

Ridge 回归与 Lasso 回归

1. 岭回归与 Lasso 引入正则化的共同目的

普通线性回归例如采用最小二乘：

$$\min_{\beta} \|y - X\beta\|_2^2.$$

岭回归与 Lasso 分别为

$$\text{Ridge: } \min_{\beta} \|y - X\beta\|_2^2 + \lambda \|\beta\|_2^2,$$

$$\text{Lasso: } \min_{\beta} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1.$$

二者共同目的都是限制参数规模，抑制模型复杂度，从而减小过拟合风险，提高对未见数据的泛化能力；同时也可缓解多重共线性引起的参数不稳定。

答：通过正则化约束参数规模，降低模型复杂度和方差，缓解过拟合与参数不稳定，提高泛化能力。

2. 为什么 Lasso 能做特征选择，而岭回归通常不能？

Lasso 使用 L_1 正则项

$$\lambda \sum_{j=1}^p |\beta_j|.$$

其约束区域在坐标轴方向有尖角，最优点容易落在坐标轴上，使部分系数精确等于 0，从而直接剔除相应特征，得到稀疏模型。

岭回归使用 L_2 正则项

$$\lambda \sum_{j=1}^p \beta_j^2.$$

其约束区域光滑，通常只会连续压缩系数，使其接近 0，但一般不会精确变为 0。

答：Lasso 的 L_1 惩罚具有稀疏性，可将部分系数压缩为精确的 0；岭回归的 L_2 惩罚通常只使系数缩小而不变为精确的 0。

3. 当 λ 变大时，模型会发生什么变化？

λ 控制正则化强度。随着 λ 增大，参数受到更强约束。

对岭回归，各系数绝对值通常进一步减小；对 Lasso，不仅系数整体减小，而且更多系数可能直接被压缩为 0。因此模型复杂度降低、方差通常减小，而偏差通常增大。若 λ 过大，则会导致欠拟合。

答： λ 越大，正则化越强，系数越趋近于 0；Lasso 中会有更多系数变为 0。模型复杂度降低、方差减小、偏差增大，过大时产生欠拟合。

4. 什么时候更偏向使用岭回归，什么时候更偏向使用 Lasso？

更偏向岭回归的情况：

- 大多数特征都可能对输出有一定贡献，希望保留全部特征；
- 特征之间存在较强相关性，希望稳定参数估计；
- 更关注预测稳定性，而不是显式变量筛选。

更偏向 Lasso 的情况：

- 认为真正有用的特征只占少数，即模型具有稀疏性；
- 希望自动进行特征选择，获得更简洁、更易解释的模型；
- 特征维度较高，希望通过稀疏化降低有效模型规模。

当多个特征高度相关时，Lasso 可能在相关特征之间做出不稳定选择；若既希望稀疏又希望对相关特征更稳定，可考虑 Elastic Net。

答：特征普遍有效、相关性强且希望稳定保留变量时优先岭回归；认为只有少数特征重要、需要变量筛选和稀疏解释时优先 Lasso。

5. 训练前为什么要对特征做标准化？

Ridge 与 Lasso 的正则项直接作用于回归系数。若不同特征的量纲和数值尺度差异很大，则同样大小的系数对应的实际影响不同，正则化会对各特征产生不公平的惩罚。

通常将第 j 个特征标准化为

$$x'_j = \frac{x_j - \mu_j}{\sigma_j}.$$

这样各特征尺度近似一致，系数大小更具可比性， λ 对各特征的惩罚更公平，同时也有利于数值优化的稳定性和收敛速度。

答：标准化可消除量纲和尺度差异，使正则项对不同特征的惩罚具有可比性，并提高数值优化稳定性。否则尺度较大的特征可能因系数较小而受到相对较弱的惩罚。