《大数据解析与应用》历年小测题

标准参考解答与考前速查

对应上传资料《小测题.pdf》共 5 页｜含 2024 与 2025 年题目｜整理日期：2026-10-18

使用说明 本文按上传 PDF 的年份及页码逐题整理。原题中有截图、笔记和部分标注的参考答案；本文保留其考查方向，并用标准数学定义给出**独立解释**。对于语义含糊或需要前提的题目，会标明通常判法/成立条件，并非教师官方标准答案。**考前建议：先闭卷做原题，再用本册订正。**

第一部分｜答案速查表

2025 年｜原 PDF 第 1–5 页

来源	题目核心	参考答案
P1-1	哪种场景适合回归分析?	**B**（连续值天气预测）
P1-2	数据归一化常用方法（多选）	**B、C**
P2-3	OLS→Ridge→Lasso→Elastic Net；PCR/PLSR	详见发展图
P3-1	两种典型拟合不佳（多选）	**A、B**
P3-2	CCA 典型变量正交关系（多选）	**A、B、C**
P3-3	PLS 的方法思想组合（多选）	**A、B、C**（概念意义）
P3-4	CCA 最多能提取多少对典型变量	**两组秩的较小值**
P4-1	样本顺序影响 K 均值结果	**B ／错**（标准批量版本）
P4-2	Fisher 判别与投影类中心距离	**A ／对**（需顾及类内散度）
P4-3	CCA 用于研究两组变量的关系	**A ／对**
P4-4	在给定 $O(n^2)$ 前提下 SVM 不宜的数据规模	**D ／大规模**
P5-5	CCA 选择典型变量的目标	**B ／最大相关系数**

2024 年｜原 PDF 第 1 页

题号	题目核心	参考结论
1	正交投影矩阵用于降维的优势	保证正交、稳定、易解释
2	PCA 约束条件	单位范数、两两正交
3	PCA 与慢特征分析区别	最大方差 vs 最小时间变化
4	数据清洗具有数据降维的作用	**错**（按一般定义）
5	归一化可以消除量纲与取值范围差异	**对**（注意方法差异）
6	箱形图上下四分位间约占一半数据	**对**
7	构造新属性能够提升数据挖掘效果	**对**（可能提升）

第二部分｜ 2024 年题目逐题解答

A. 2024.10.10（原 PDF 第 1 页上半部分）

1. 正交投影矩阵用于降维的优点是什么?

参考答案：无冗余方向、几何与数值性质清晰，能构成最优正交投影。

设 $X \in \mathbb{R}^{n\times p}$ 为中心化数据，降维方向矩阵 $W \in \mathbb{R}^{p\times k}$，$k < p$。常用约束是 $W^\top W = I_k$；对应投影算子 $P = WW^\top$ 满足 $P^\top = P$、$P^2 = P$。其优势：

1. **消除方向冗余**：正交基不会重复描述同一个投影方向。
2. **数值稳定**：列向量单位范数，避免投影坐标任意放大或缩小，便于后续计算。
3. **几何清晰**：$\hat{x} = WW^\top x$ 是到给定子空间的最短欧氏距离投影。
4. **便于优化**：PCA 选择合适的正交子空间后，能在给定维数下最大化保留的总方差，等价于最小化平方重构误差。

易错：W 是矩形列正交矩阵，并不是方阵意义上的 $W^{-1} = W^\top$；降维后不会保留原空间所有信息或所有两两距离。

2. 主成分分析（PCA）的约束条件。

参考答案：各主成分方向单位范数、两两正交；在这些约束下最大化投影方差。

令 $\Sigma = \frac{1}{n}X^\top X$，第 j 个主成分方向满足

$$\max_{w_j} \; w_j^\top \Sigma w_j, \quad w_j^\top w_j = 1, \quad w_j^\top w_i = 0 \;(i < j).$$

将 k 个方向合并：$\max_{W^\top W = I_k} \operatorname{tr}(W^\top \Sigma W)$。最优解为协方差矩阵最大的 k 个特征值对应的正交特征向量。由此不同主成分得分不相关：$\operatorname{Cov}(Xw_i, Xw_j) = 0$ $(i \neq j)$。

3. PCA 与慢特征分析（SFA）有何区别?

参考答案：PCA 找“变化幅度大”的方向；SFA 找“随时间变化慢”的方向。

角度	PCA	SFA
主要目标	最大化 $\mathrm{Var}(w^\top x)$	最小化 $\mathbb{E}[(\Delta y_t)^2]$
主要约束	投影方向正交、单位范数	输出均值零、方差一、不同输出去相关
是否利用时间顺序	一般不利用	必须利用样本时序关系
典型用途	方差解释、压缩、降噪	缓慢状态提取、动态系统特征

SFA 可记为 $\min\ \mathbb{E}[(y_t - y_{t-1})^2]$，其中 $\mathbb{E}[y] = 0$、$\mathbb{E}[y^2] = 1$；单位方差约束防止退化为常数输出。

4–7. 判断题。

4. **错。**数据清洗主要处理缺失、错误、异常及重复记录；降维一般属于特征选择或特征提取。删除冗余特征也可能降低维数，但不能说清洗必然具有降维作用。

5. **对。**归一化/标准化使特征按统一尺度表达，可消除量纲，缓解不同取值范围造成的数值不平衡。注意：Z-score 不保证输出落在同一区间，Min–Max 才常映射到指定区间。

6. **对。**箱线图 Q_1 至 Q_3 对应第 25% 到第 75% 分位，四分位距 $IQR = Q_3 - Q_1$ 所覆盖的中心部分约占 50%；大量相同数值时边界计数可能有差异。

7. **对（作为可能性命题）。**特征构造可显露非线性关系、交互或物理意义，提高预测/挖掘效果；但无关或噪声特征也可能使性能下降，并不保证一定提升。

B. 2024 年最后一次课的小测选项（原 PDF 第 1 页中部）

选项 1（1）简述 PCA 算法。

参考答案：标准化/中心化 $\rightarrow$ 协方差或 SVD$\rightarrow$ 特征分解 $\rightarrow$ 选主成分 $\rightarrow$ 投影。

X 按列中心化（量纲差异大时先标准化）；求 $\Sigma = X^\top X/n$，特征分解 $\Sigma w_j = \lambda_j w_j$，按照 $\lambda_1 \geq \cdots \geq \lambda_p$ 排序；根据累计解释方差 $\sum_{i=1}^{k} \lambda_i / \sum_{i=1}^{p} \lambda_i$ 选 k；得到低维得分 $T = XW_k$。答题强调：*PCA* 无监督，以最大方差和正交性为核心。

选项 1（2）简述 OLS；何为多重共线性、如何改进?

参考答案：最小化残差平方和；多重共线性指解释变量之间存在强线性依赖。

$$\hat{\beta}_{\mathrm{OLS}} = \arg\min_{\beta} \|y - X\beta\|_2^2, \quad X^\top X \text{ 可逆时} \hat{\beta} = (X^\top X)^{-1} X^\top y.$$

共线性使 $X^\top X$ 病态甚至不可逆，系数方差大、符号和数值可能不稳定，导致解释性受损。可用**岭回归**（L_2 惩罚）、**LASSO**（L_1 稀疏）、**弹性网络**（$L_1 + L_2$）、**PCR/PLSR**（潜变量降维），或者删去冗余变量。若严格秩亏，可用广义逆求一组 OLS 解，但不意味着参数可唯一辨识。

选项 1（3）岭回归与 LASSO 的异同。

$$\hat{\beta}_{\text{ridge}} = \arg\min_{\beta}\big(\|y - X\beta\|_2^2 + \lambda\|\beta\|_2^2\big), \qquad \hat{\beta}_{\text{lasso}} = \arg\min_{\beta}\big(\|y - X\beta\|_2^2 + \lambda\|\beta\|_1\big).$$

共同点：在 OLS 损失上加惩罚，缓解过拟合及共线性（通常先标准化特征；截距不惩罚）。区别：岭回归用 L_2 连续收缩，一般**不产生精确零系数**、适合高度相关特征；LASSO 用 L_1 可把部分系数压成**零**实现特征选择，但相关特征间的选择可能不稳定。弹性网络同时有 L_1, L_2，兼顾稀疏与稳定性。

选项 1（4）回归分析的优点、缺点及改进方向。

参考答案：优点：可解释、实现简单、训练快，可用系数定量描述变量关系。

缺点：经典线性模型难以刻画非线性和复杂交互；多重共线性使系数不稳定；离群点与不满足噪声假设的数据可能影响估计；复杂高维场景可能过拟合。改进：正则化、稳健回归、特征变换/非线性项、PCR/PLSR、交叉验证与特征筛选。不要把“回归”泛化为只适用于线性模型；题目常特指普通线性回归。

选项 1（5）典型相关分析（CCA）与偏最小二乘（PLS）的区别。

对象	CCA	PLS / PLSR
核心目标	最大化两组投影的**相关系数** $\mathrm{Corr}(Xa, Yb)$	常以最大化两组潜变量**协方差**为核心，兼顾解释和预测
侧重点	衡量 X, Y 两组数据的相关结构	从 X 提取对预测 Y 有用的潜变量
高维/共线性	原始 CCA 可能遇到奇异协方差，需降维/正则化	PLSR 常用于高维、强共线性预测

相关系数经方差归一化；协方差未必。PLS 与 CCA 在具体实现算法上有变体，记住“相关 vs 协方差/预测”的典型区别即可。

选项 2：把本课程学过的方法联系起来讲述。

参考答案：按“预处理—目的—模型—检验”组织，比强行把所有算法连成一条链更合理。

1. 数据清洗（异常/缺失/重复）与归一化，得到质量可控的数据；
2. 数据特征处理：PCA/SFA（降维或动态特征），或者构造与任务有关的新特征；
3. 根据任务分支：回归用 OLS、Ridge、LASSO、Elastic Net 或 PCR/PLSR；两组变量关联用 CCA；聚类用 K 均值；监督判别用 Fisher/LDA、SVM；
4. 以测试集表现、泛化能力、稳定性与可解释性检验，不只看训练误差。

第三部分 | 2025 年题目逐题解答

A. 原 PDF 第 1 页：基础选择题

1. 下列场景适用于回归分析的是（单选）。

参考答案：B. 天气预报。

回归预测的是**连续数值**，例如气温、降水量、风速；水果分拣、人脸识别常为分类，信息浓缩常为降维。严格说“天气预报”也可以是晴雨分类，因此原题语义不够精确；这里按预测连续气象量的常见出题意图选 B。

2. 一般常见的数据归一化方法是（多选）。

参考答案：B. 最小–最大规范化；C. 零均值规范化。

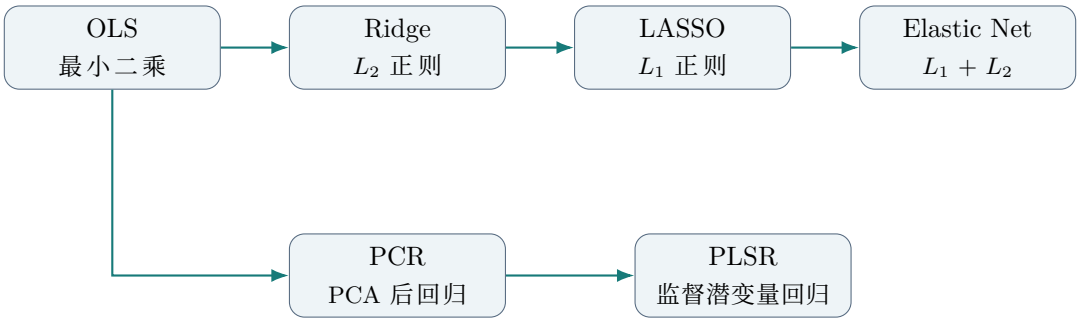
$$\text{Min–Max: } x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}, \qquad \text{Z-score: } x' = \frac{x - \mu}{\sigma}.$$

A. 替换填充法、D. 回归填充法属于**缺失值处理**，不是归一化。注意零均值规范化通常是零均值单位标准差；标准差为零时要单独处理。

B. 原 PDF 第 2 页：6 分简答题（必练）

3. 绘制 OLS→Ridge→Lasso→Elastic Net 演进路线，并添加 PCR/PLSR 分支。

参考答案：下面为符合题干要求的概念演进图，箭头表示“针对前一步局限的建模选择”，不是历史上严格线性替代关系。



每一步的局限与机制（考试写法）

1. **OLS：** $\min \|y - X\beta\|_2^2$。共线性使估计高方差/不稳定，也可能过拟合。
2. **Ridge：** 加 $\lambda\|\beta\|_2^2$，收缩系数、改善病态问题；局限是一般不能自动筛掉无关变量。
3. **LASSO：** 加 $\lambda\|\beta\|_1$，系数可被压为零，实现稀疏特征选择；强相关变量可能被不稳定地择一选入。
4. **Elastic Net：** $\min \|y - X\beta\|_2^2 + \lambda_1\|\beta\|_1 + \lambda_2\|\beta\|_2^2$，同时获得稀疏性和相关变量的组效应/稳定性。

PCR 与 PLSR 分支（同属潜变量路线，但目标不同）

- **PCR：** 对 X 做 PCA，选解释 X 方差最大的 k 个方向，再用这些得分回归 Y。优点是降维去共线性；缺点是高方差方向未必对预测 Y 最有用。
- **PLSR：** 考虑 X 与 Y 的共同信息来提取潜变量，再进行回归；方向与预测目标更相关，适合多重共线性、高维及多输出预测。核心不是单纯追求 X 方差最大。

6 分题拿分关键词： OLS 的共线性；Ridge 的 L_2 收缩但不稀疏；LASSO 的 L_1 稀疏但强相关选择不稳定；Elastic Net 联合惩罚；PCR 先无监督 PCA 再回归；PLSR 提取与 Y 有关的潜变量。

C. 原 PDF 第 3 页：拟合、CCA、PLS

1. 最典型的两种拟合不佳情况是（多选）。

参考答案：A. 欠拟合；B. 过拟合。

欠拟合：模型容量不足，训练与测试误差可能都较高；过拟合：过度记忆训练数据，训练误差低而测试误差可能明显上升。C“强拟合”、D“弱拟合”不是常用的两类规范术语。

2. CCA 的哪些“垂直（正交）”关系成立（多选）?

参考答案：A、B、C；D 错。

令中心化后的两组数据为 X, Y，$U_i = a_i^\top X$、$V_i = b_i^\top Y$，协方差分别为 Σ_{11}, Σ_{22}。在**标准 CCA 的典型变量归一化与排序约束**下，不同编号的典型变量满足：

$$\mathrm{Cov}(U_i, U_j) = 0, \quad \mathrm{Cov}(V_i, V_j) = 0, \quad \mathrm{Cov}(U_i, V_j) = 0 \quad (i \neq j).$$

因此 **A、B、C** 成立。权重向量的归一化/正交对应

$$a_i^\top \Sigma_{11} a_j = \delta_{ij}, \qquad b_i^\top \Sigma_{22} b_j = \delta_{ij},$$

而不是 D 所说的 $a_i^\top \Sigma_{11}^{-1} a_j = 0$。**D 把协方差度量误写成了其逆矩阵。** 答题时区分：U_i 的正交是“典型变量”的不相关；a_i 的正交是按 Σ_{11} 加权，不是普通欧氏正交。

3. PLS 可看作哪些方法思想的结合（多选）?

参考答案：A. OLS；B. PCA；C. CCA。

PLSR 同时包含**回归预测**（与 OLS 目标有关）、**潜变量/降维**（与 PCA 思想有关）、**协调 X, Y 信息**（与 CCA 思想有关）。D. RR 岭回归不是其直接的基本构成。“思想结合”不等于 PLS 在算法上恰好等于三者相加；具体教材表述可能略有区别。

4. CCA 可提取的典型变量对数最大受何限制?

参考答案：两组变量各自秩中的较小值。

$$\boxed{k_{\max} \leq \min\big(\mathrm{rank}(X), \mathrm{rank}(Y)\big)}.$$

如果协方差矩阵可逆，常简写为 $\min(p, q)$；中心化后还受样本数 $n - 1$ 约束。若问“非零相关的典型对”数量，还受交叉协方差矩阵秩的进一步限制。

D. 原 PDF 第 4–5 页：判断及单选

第 4 页第 1 题. 样本顺序会影响 K 均值聚类结果。

参考答案：B. 错误（与题源标注一致）。

固定初始中心、采用**标准批量 K-means** 且无特殊并列距离处理时，样本排列不会改变目标函数及赋类/均值更新。但随机中心选取、在线/增量算法以及特定实现的先后处理，可能使最终结果不同。区分“样本顺序”与“初始化随机性”。

第 4 页第 2 题. Fisher 判别以投影后各类中心点间距离衡量类间分离度。

参考答案：A. 正确（与题源参考答案一致）。

双类 Fisher 判别不仅鼓励投影后的均值分离，也抑制同类内部离散：

$$J(w) = \frac{w^\top S_b w}{w^\top S_w w}.$$

类中心距离体现 S_b，完整目标是**类间散度大、类内散度小**。“只最大化中心距离”不是完整的 Fisher 目标。

第 4 页第 3 题. CCA 适用于分析两组变量之间的关系。

参考答案：A. 正确（与题源参考答案一致）。

CCA 寻找两组变量的线性组合，使对应典型变量的 Pearson 相关最大，可分析两组多变量数据间的相关结构。

第 4 页第 4 题. 给定 SVM 最小时间复杂度 $O(n^2)$，哪种数据集不适宜?

参考答案：D. 大规模数据集（与题源参考答案一致）。

按题干的二次复杂度前提，n 增加时计算负担增长较快。题干给出的复杂度是特定前提，并非所有 SVM 求解器和场景都固定为 $O(n^2)$；大数据也可考虑近似线性 SVM 或其他优化策略。

第 5 页第 5 题. CCA 选择综合变量的目标是什么?

参考答案：B. 最大化两者的相关系数（与题源参考答案一致）。

$$\max_{a,b} \quad \rho(a,b) = \frac{a^\top \Sigma_{XY} b}{\sqrt{a^\top \Sigma_{XX} a}\sqrt{b^\top \Sigma_{YY} b}}, \quad a^\top \Sigma_{XX} a = 1,\ b^\top \Sigma_{YY} b = 1.$$

CCA 最大化的是经过方差归一化的**相关系数**，不是欧氏距离、也不是未经归一化的协方差。

第四部分 | 考前一页速记

最值得先拿的分 2025 年第 2 页的 **6 分回归演进简答**；第 3 页 **CCA 正交多选**；2024 年的 **PCA / OLS / Ridge–LASSO / SFA** 五道简答。

考点	一句话识别 + 必背点
PCA	最大投影方差；$W^\top W = I$；无监督；特征值最大方向。
SFA	最小输出**时间变化**，单位方差防常数解；需要时序。
OLS	$\min \|y - X\beta\|_2^2$；多重共线性使系数不稳。
Ridge	L_2：系数收缩、稳健，**通常不稀疏**。
LASSO	L_1：**可稀疏选特征**，相关变量选择可能不稳。
Elastic Net	$L_1 + L_2$：兼顾稀疏与相关变量分组稳定性。
PCR	PCA(X) 之后再回归 Y，不考虑主成分与 Y 的关联。
PLSR	选取与 Y 有关的潜变量，再做回归；综合降维与预测。
CCA	两组投影**相关系数最大**；标准形式不同典型编号交叉不相关。
CCA 约束	$a_i^\top \Sigma_{XX} a_j = \delta_{ij}$，**不是** Σ_{XX}^{-1}。
K-means	标准批量算法固定初始中心时与样本顺序无关，**初始化影响解**。
Fisher / LDA	最大类间散度/类内散度之比，非仅增大均值距离。
规范化	Min–Max、Z-score；缺失值**填充**不是归一化。

考前最后 3 个口述题 不看答案，能否在 60 秒内讲清楚：

1. 为什么 Ridge → LASSO → Elastic Net 可视作“从稳健到稀疏再兼顾相关组”的思路?
2. 为什么 CCA 中 U_i, U_j 不相关，并不意味着权重向量 a_i, a_j 按普通欧氏内积或 Σ_{XX}^{-1} 内积正交?
3. PCR 与 PLSR 都用潜变量，为什么 PCR 可能丢掉对 Y 有预测力的低方差方向?

题源与边界 本册以用户上传的五页《小测题.pdf》为基础（2024 题型回忆、2025 小测题及部分题源参考答案/手写笔记）。2025 年第 1 页“天气预报”题、2024 数据清洗/特征构造判断、K-means 顺序题、Fisher 表述与 SVM 复杂度题均具有上下文限定；本文已说明通常考试判法与理论条件，请优先以任课教师课件的具体定义为准。